

Logika rozmyta, wykład 2

Joanna Jędrzejowicz

Instytut Informatyki

Pojęcia nieprecyzyjne, np

- wysoka temperatura,
- dobry uczeń,
- duże miasto
- ..

klasyczna teoria zbiorów i logika nie wystarczają do opisu
Lofti A. Zadeh 1965 Teoria zbiorów rozmytych

Zbiór rozmyty - definicja

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Zbiór rozmyty w przestrzeni X

Zbiór rozmyty jest zbiorem par $A = \{(x, \mu_A(x)) | x \in X\}$, gdzie $\mu_A : X \rightarrow [0, 1]$ jest funkcją przynależności zbioru rozmytego.

Jeżeli $X = \{x_1, \dots, x_n\}$ to zbiór rozmyty zapisuje się:

$$A = \frac{\mu_A(x_1)}{x_1} + \dots + \frac{\mu_A(x_n)}{x_n}$$

uwaga: teoria zbiorów rozmytych opisuje niepewność, nie prawdopodobieństwo

Przykład

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Określamy pojęcie zbioru liczb naturalnych 'bliskich 7'.
definiujemy zbiór rozmyty

$$A = \frac{0.2}{4} + \frac{0.5}{5} + \frac{0.8}{6} + \frac{1}{7} + \frac{0.8}{8} + \frac{0.5}{9} + \frac{0.2}{10}$$



Zadanie

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

zadanie: zdefiniować zbiór rozmyty odpowiadający pojęciu
'temperatura w Bałtyku odpowiednia do kąpieli'.

Przykłady standardowych funkcji przynależności

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

- Funkcja singleton

$$\mu_a(x) = \begin{cases} 1 & \text{jeżeli } x = \bar{x} \\ 0 & \text{w przeciwnym przyp} \end{cases}$$

- Gaussowska funkcja przynależności, \bar{x} - środek, σ - szerokość krzywej

$$\mu_A(x) = \exp\left(-\left(\frac{x - \bar{x}}{\sigma}\right)^2\right)$$

- funkcja przynależności typu dzwonowego, a - szerokość, b - nachylenie, c - środek

$$\mu_A(x) = \frac{1}{1 + \left|\frac{x-c}{a}\right|^{2b}}$$

Przykłady standardowych funkcji przynależności, cd

- funkcja klasy s

$$s(x; a, b, c) = \begin{cases} 0 & \text{jeżeli } x \leq a \\ 2\left(\frac{x-a}{c-a}\right)^2 & \text{dla } a < x \leq b \\ 1 - 2\left(\frac{x-c}{c-a}\right)^2 & \text{dla } b < x \leq c \\ 1 & \text{dla } x > c \end{cases}$$

gdzie $b = \frac{a+c}{2}$

- funkcja przynależności klasy Π

$$\Pi(x; b, c) = \begin{cases} s(x; c-b, c-\frac{b}{2}, c) & \text{jeżeli } x \leq c \\ 1 - s(x; c, c+\frac{b}{2}, c+b) & \text{dla } x > c \end{cases}$$

Nośnik i wysokość zbioru rozmytego

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Nośnik zbioru rozmytego

Zbiór elementów przestrzeni X , dla których $\mu_A(x) > 0$ nazywamy nośnikiem zbioru rozmytego i oznaczamy $\text{supp}A$

$$\text{supp}A = \{x \in X \mid \mu_A(x) > 0\}$$

Wysokość zbioru rozmytego

Wysokość zbioru rozmytego A

$$h(A) = \sup_{x \in X} \mu_A(x)$$

W przykładzie $\text{supp}A = \{4, 5, 6, 7, 8, 9, 10\}$ oraz $h(A) = 1$.

Operacje na zbiorach rozmytych

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Przecięciem zbiorów rozmytych $A, B \subset X$ jest zbiór rozmyty $A \cap B$ o funkcji przynależności:

$$\mu_{A \cap B} = \min(\mu_A(x), \mu_B(x))$$

Sumą zbiorów rozmytych $A, B \subset X$ jest zbiór rozmyty $A \cup B$ o funkcji przynależności:

$$\mu_{A \cup B} = \max(\mu_A(x), \mu_B(x))$$

Przykład

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Założmy, że $X = \{1, 2, 3, 4, 5, 6, 7\}$ oraz

$$A = \frac{0.9}{3} + \frac{1}{4} + \frac{0.6}{6}$$

$$B = \frac{0.7}{3} + \frac{1}{5} + \frac{0.4}{6}$$

wtedy

$$A \cap B = \frac{0.7}{3} + \frac{0.4}{6}$$

$$A \cup B = \frac{0.9}{3} + \frac{1}{4} + \frac{1}{5} + \frac{0.6}{6}$$

Operacje przecięcia i sumy można definiować także ogólniej przy pomocy tzw. norm

$$\mu_{A \cap B} = T(\mu_A(x), \mu_B(x))$$

gdzie T jest t-normą (np. $T(x, y) = \min(x, y)$)

Warunki dla norm

Norma $T : [0, 1]^2 \rightarrow [0, 1]$ spełnia nast. warunki:

- funkcja T jest niemalejąca względem obu argumentów

$$T(a, c) \leq T(b, d) \quad a \leq b, c \leq d$$

Warunki dla norm

Norma $T : [0, 1]^2 \rightarrow [0, 1]$ spełnia nast. warunki:

- funkcja T jest niemalejąca względem obu argumentów

$$T(a, c) \leq T(b, d) \quad a \leq b, c \leq d$$

- spełnia warunek przemienności

$$T(a, b) = T(b, a)$$

Warunki dla norm

Norma $T : [0, 1]^2 \rightarrow [0, 1]$ spełnia nast. warunki:

- funkcja T jest niemalejąca względem obu argumentów

$$T(a, c) \leq T(b, d) \quad a \leq b, c \leq d$$

- spełnia warunek przemienności

$$T(a, b) = T(b, a)$$

- spełnia warunek łączności

$$T(T(a, b), c) = T(a, T(b, c))$$

Warunki dla norm

Norma $T : [0, 1]^2 \rightarrow [0, 1]$ spełnia nast. warunki:

- funkcja T jest niemalejąca względem obu argumentów

$$T(a, c) \leq T(b, d) \quad a \leq b, c \leq d$$

- spełnia warunek przemienności

$$T(a, b) = T(b, a)$$

- spełnia warunek łączności

$$T(T(a, b), c) = T(a, T(b, c))$$

- spełnia warunek brzegowy

$$T(a, 1) = a$$

skąd wynika $T(a, 0) = 0$ bo

$$T(a, 0) = T(0, a) \leq T(0, 1) = 0$$

Relacje rozmyte

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Relacje rozmyte mogą formalizować pojęcia takie jak 'x prawie równe y', 'x znacznie większy od y' itd

$$R \subset X \times Y, \mu_R : X \times Y \rightarrow [0, 1]$$

Przykład. Definiujemy relację R 'y prawie równe x' dla $X = \{3, 4, 5\}$, $Y = \{4, 5, 6\}$

$$\begin{aligned} R = & \frac{1}{(4, 4)} + \frac{1}{(5, 5)} + \frac{0.8}{(3, 4)} + \frac{0.8}{(4, 5)} \\ & + \frac{0.8}{(5, 4)} + \frac{0.8}{(5, 6)} + \frac{0.6}{(3, 5)} + \frac{0.6}{(4, 6)} + \frac{0.4}{(3, 6)} \end{aligned}$$

Złożenie relacji rozmytych

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Złożeniem relacji rozmytych $R \subset X \times Y$ oraz $S \subset Y \times Z$ jest relacja rozmyta $R \circ S \subset X \times Z$ z funkcją przynależności

$$\mu_{R \circ S}(x, z) = \sup_{y \in Y} T(\mu_R(x, y), \mu_S(y, z))$$

gdzie T jest normą.

Złożenie relacji rozmytych

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Złożeniem relacji rozmytych $R \subset X \times Y$ oraz $S \subset Y \times Z$ jest relacja rozmyta $R \circ S \subset X \times Z$ z funkcją przynależności

$$\mu_{R \circ S}(x, z) = \sup_{y \in Y} T(\mu_R(x, y), \mu_S(y, z))$$

gdzie T jest normą.

Złożenie zbioru rozmytego $A \subset X$ i relacji rozmytej $R \subset X \times Y$ oznaczamy $A \circ R$ i definiujemy jako zbiór rozmyty $B \subset Y$ z funkcją przynależności

$$\mu_{A \circ R}(y) = \sup_{x \in X} T(\mu_A(x), \mu_R(x, y))$$

Zmienne lingwistyczne

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Zmienna lingwistyczna jest czwórką postaci (N, T, X, M_N) gdzie

N - nazwa zmiennej, np. prędkość samochodu

T - zbiór wartości zmiennej, np (duża, średnia, mała)

X - przestrzeń rozważań

M_N funkcja semantyczna, która każdej wartości $t \in T$ przyporządkowuje funkcję przynależności

Rozmyte reguły wnioskowania

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Reguła *modus ponens* w logice dwuwartościowej:
przesłanka: A ,
implikacja: $A \rightarrow B$,
wniosek: B

Rozmyte reguły wnioskowania

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Reguła *modus ponens* w logice dwuwartościowej:

przesłanka: A ,

implikacja: $A \rightarrow B$,

wniosek: B

Przypadek rozmyty: zakładamy, że A i B odpowiadają pewne zbiory rozmyte, funkcja przynależności $\mu_{A \rightarrow B}(x, y)$ rozmytej implikacji $A \rightarrow B$ jest równoważna pewnej relacji rozmytej $R \subset X \times Y$ z funkcją przynależności

$$\mu_{A \rightarrow B}(x, y) = T(\mu_A(x), \mu_B(y))$$

gdzie T jest normą,

Rozmyte reguły wnioskowania, cd

Najczęściej używane reguły dla rozmytej implikacji:

1

$$\mu_{A \rightarrow B}(x, y) = \min(\mu_A(x), \mu_B(y))$$

2

$$\mu_{A \rightarrow B}(x, y) = \mu_A(x) \cdot \mu_B(y)$$

3

$$\mu_{A \rightarrow B}(x, y) = \min(1, 1 - \mu_A(x) + \mu_B(y))$$

4

$$\mu_{A \rightarrow B}(x, y) = \begin{cases} 1 & \text{jesli } \mu_A(x) \leq \mu_B(y) \\ 0 & \text{jesli } \mu_A(x) > \mu_B(y) \end{cases}$$

Rozmyte reguły wnioskowania, cd

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Wniosek reguły rozmytej odnosi się do pewnego zbioru rozmytego B' , który jest określony przez złożenie zbioru rozmytego A' i rozmytej implikacji $A \rightarrow B$

$$B' = A' \circ A \rightarrow B$$

Rozmyte reguły wnioskowania, przykład

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

przesłanka: Prędkość samochodu jest duża
implikacja: Jeżeli prędkość samochodu jest bardzo duża, to
poziom hałas jest wysoki
wniosek : Poziom hałas jest średnio wysoki.

Rozmyte reguły wnioskowania, przykład

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

przesłanka: Prędkość samochodu jest duża

implikacja: Jeżeli prędkość samochodu jest bardzo duża, to
poziom hałas jest wysoki

wniosek : Poziom hałas jest średnio wysoki.

Zmienne lingwistyczne:

x- prędkość samochodu, y-poziom hałas,

Zbiory rozmyte:

A-bardzo duża prędkość samochodu, A'-duża prędkość
samochodu, B- wysoki poziomy hałas, B'- średnio wysoki
poziomy hałas (wniosek z przesłanki)

Rozmyte reguły wnioskowania, przykład

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

przesłanka: Prędkość samochodu jest duża (A')

implikacja: Jeżeli prędkość samochodu jest bardzo duża (A), to
poziom hałas jest wysoki (B)

wniosek : Poziom hałas jest średnio wysoki (B').

Rozmyte reguły wnioskowania, przykład

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

przesłanka: Prędkość samochodu jest duża (A')

implikacja: Jeżeli prędkość samochodu jest bardzo duża (A), to poziom hałasu jest wysoki (B)

wniosek : Poziom hałasu jest średnio wysoki (B').

Jeśli przyjąć

$$\mu_{A \rightarrow B}(x, y) = \min(\mu_A(x), \mu_B(y))$$

to

$$\mu_{B'}(y) = \max_{x \in X} \min(\mu'_A(x), \min(\mu_A(x), \mu_B(y)))$$

Zastosowanie - podejmowanie decyzji w otoczeniu rozmytym

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Dany jest pewien zbiór opcji (wyborów) X_{op} . **Cel rozmyty** G jest określony przy pomocy funkcji przynależności μ_G , która dla każdego $x \in X_{op}$ określa stopień przynależności opcji do zbioru rozmytego. Ponadto, dane jest **ograniczenie rozmyte** C dane przy pomocy funkcji przynależności μ_C .

Decyzja rozmyta $D = G \cap C$ jest interpretowana jako 'osiągnąć G i spełnić C ', przy czym

$$\mu_D(x) = T(\mu_G(x), \mu_C(x))$$

gdzie T jest normą. Poszukuje się decyzji maksymalizującej μ_D .

Zastosowanie - podejmowanie decyzji w otoczeniu rozmytym

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Dany jest pewien zbiór opcji (wyborów) X_{op} . **Cel rozmyty** G jest określony przy pomocy funkcji przynależności μ_G , która dla każdego $x \in X_{op}$ określa stopień przynależności opcji do zbioru rozmytego. Ponadto, dane jest **ograniczenie rozmyte** C dane przy pomocy funkcji przynależności μ_C .

Decyzja rozmyta $D = G \cap C$ jest interpretowana jako 'osiągnąć G i spełnić C ', przy czym

$$\mu_D(x) = T(\mu_G(x), \mu_C(x))$$

gdzie T jest normą. Poszukuje się decyzji maksymalizującej μ_D .

Uwaga. Często $G = G_1 \cap \dots \cap G_n$ jest wiele celów i wiele ograniczeń $C = C_1 \cap \dots \cap C_m$

Przykład - polityka zatrudnienia

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

W firmie jest konkurs na stanowisko asystenta dyrektora. Dla kandydatów ustalono następujące kryteria oceny:

- G_1 - doświadczenie,
- G_2 - obsługa programów biurowych,
- G_3 - młody wiek,
- G_4 - znajomość języków obcych

Kandydaci x_1, x_2, x_3, x_4 są oceniani z punktu widzenia celów G_1, G_2, G_3, G_4 oraz spełnienia ograniczenia C związanego z gotowością kandydatów do zaakceptowania oferowanego wynagrodzenia.

Przykład - polityka zatrudnienia, cd

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Założmy, że zbiory rozmyte odpowiadające poszczególnym kryteriom są następujące

- $G_1 = \frac{0.7}{x_1} + \frac{0.2}{x_2} + \frac{0.5}{x_3} + \frac{0.3}{x_4}$,
- $G_2 = \frac{0.8}{x_1} + \frac{0.8}{x_2} + \frac{0.5}{x_3} + \frac{0.2}{x_4}$,
- $G_3 = \frac{0.7}{x_1} + \frac{0.8}{x_2} + \frac{0.4}{x_3} + \frac{0.5}{x_4}$,
- $G_4 = \frac{0.5}{x_1} + \frac{0.6}{x_2} + \frac{0.7}{x_3} + \frac{0.8}{x_4}$
- $C = \frac{0.3}{x_1} + \frac{0.4}{x_2} + \frac{0.6}{x_3} + \frac{0.9}{x_4}$

Decyzja D jest

$$D = G_1 \cap G_2 \cap G_3 \cap G_4 \cap C$$

Przykład - polityka zatrudnienia, cd

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Założmy, że zbiory rozmyte odpowiadające poszczególnym kryteriom są następujące

- $G_1 = \frac{0.7}{x_1} + \frac{0.2}{x_2} + \frac{0.5}{x_3} + \frac{0.3}{x_4}$,
- $G_2 = \frac{0.8}{x_1} + \frac{0.8}{x_2} + \frac{0.5}{x_3} + \frac{0.2}{x_4}$,
- $G_3 = \frac{0.7}{x_1} + \frac{0.8}{x_2} + \frac{0.4}{x_3} + \frac{0.5}{x_4}$,
- $G_4 = \frac{0.5}{x_1} + \frac{0.6}{x_2} + \frac{0.7}{x_3} + \frac{0.8}{x_4}$
- $C = \frac{0.3}{x_1} + \frac{0.4}{x_2} + \frac{0.6}{x_3} + \frac{0.9}{x_4}$

Decyzja D jest

$$D = G_1 \cap G_2 \cap G_3 \cap G_4 \cap C$$

otrzymujemy

$$D = \frac{0.3}{x_1} + \frac{0.2}{x_2} + \frac{0.4}{x_3} + \frac{0.2}{x_4}$$

wygrywa kandydat oznaczony x_3 .

Przykład - ocena studentów

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Firma ufundowała praktyki dla najlepszych studentów. Atrybut 'najlepszy' jest opisany przy pomocy zmiennych lingwistycznych, oddzielnie dla przedmiotów ścisłych (NS) oraz języków (NJ).

$$\mu_{NS}(x) = \begin{cases} 0 & \text{dla } 2 \leq x \leq 4.3 \\ \frac{x-4.3}{0.5} & \text{dla } 4.3 \leq x \leq 4.8 \\ 1 & \text{dla } 4.8 \leq x \leq 5 \end{cases}$$

$$\mu_{NJ}(x) = \begin{cases} 0 & \text{dla } 2 \leq x \leq 4.2 \\ \frac{x-4.2}{0.4} & \text{dla } 4.2 \leq x \leq 4.6 \\ 1 & \text{dla } 4.6 \leq x \leq 5 \end{cases}$$

Przykład - ocena studentów, cd

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Sześciu studentów otrzymało następujące oceny:

stud	elektr	infor	mat	ang	niem
x_1	4.8 1	5.0 1	4.7 0.8	4.3 0.25	4.7 1
x_2	4.4 0.2	4.7 0.8	4.8 1	4.4 0.5	4.4 0.5
x_3	4.9 1	4.9 1	4.6 0.6	4.7 1	4.3 0.25
x_4	4.5 0.4	4.8 1	4.9 1	5 1	4.5 0.75
x_5	5 1	4.6 0.6	4.7 0.8	4.4 0.5	5.0 1
x_6	4.9 1	4.5 0.4	5.0 1	4.5 0.75	4.4 0.5

na czerwono zaznaczono wartości funkcji przynależności

Przykład - ocena studentów, cd

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

zbiory rozmyte odpowiadające kolejnym przedmiotom:

$$G_1 = \frac{1}{x_1} + \frac{0.2}{x_2} + \frac{1}{x_3} + \frac{0.4}{x_4} + \frac{1}{x_5} + \frac{1}{x_6}$$

$$G_2 = \frac{1}{x_1} + \frac{0.8}{x_2} + \frac{1}{x_3} + \frac{1}{x_4} + \frac{0.6}{x_5} + \frac{0.4}{x_6}$$

$$G_3 = \frac{0.8}{x_1} + \frac{1}{x_2} + \frac{0.6}{x_3} + \frac{1}{x_4} + \frac{0.8}{x_5} + \frac{1}{x_6}$$

$$G_4 = \frac{0.25}{x_1} + \frac{0.5}{x_2} + \frac{1}{x_3} + \frac{1}{x_4} + \frac{0.5}{x_5} + \frac{0.75}{x_6}$$

$$G_5 = \frac{1}{x_1} + \frac{0.5}{x_2} + \frac{0.25}{x_3} + \frac{0.75}{x_4} + \frac{1}{x_5} + \frac{0.5}{x_6}$$

Przykład - ocena studentów, cd

Logika
rozmyta,
wykład 2

Joanna
Jędrzejowicz

Podstawiając $D = G_1 \cap G_2 \cap G_3 \cap G_4 \cap G_5$

Decyzja rozmyta typu minimum jest

$$D = \frac{0.25}{x_1} + \frac{0.2}{x_2} + \frac{0.25}{x_3} + \frac{0.4}{x_4} + \frac{0.5}{x_5} + \frac{0.4}{x_6}$$

Student x_5 charakteryzuje się największym stopniem przynależności i zostanie wybrany.